



北京邮电大学
Beijing University of Posts and Telecommunications

北京邮电大学
计算机学院

数据预处理和可视化作业-1

姓名: 吴清柳

学号: 2020211597

班级: 2020211323

指导老师: 王纯

课程名称: *Python* 程序设计

December 5, 2022

Contents

1	数据预处理	3
1.1	输入的 json 格式	3
1.2	处理过程	3
1.2.1	求平均值的理由	4
1.3	csv 数据格式	4
2	数据可视化	4
2.1	图表内容	4
3	程序的结构和运行	5
3.1	代码结构	5
3.1.1	数据处理部分	5
3.1.2	数据可视化部分	6
3.2	代码运行	7
4	附录	8

1 数据预处理

利用 python 的 json 库和 csv 库, 将 Scrapy 爬取的保存在 json 格式中的链家新房数据转为 csv 格式.

1.1 输入的 json 格式

由于 Scrapy 爬取的数据已经被我做过后处理, 因此看起来比较整洁. 具体格式如下:

```
[
  {
    "house_name": "尊悦日坛", // 楼盘名称
    "resblock_type": "商业类", // 类型
    "resblock_location": [ // 地理位置
      "朝阳",
      "朝阳门外",
      "日坛北路19号"
    ],
    "resblock_room": "1室", // 房型
    "resblock_area": "建面 45-135 m²", // 面积
    "house_avg_price": "63000", // 均价
    "house_total_price": "总价350-1200(万/套)" // 总价
  },
  {
    "house_name": "天恒摩墅",
    "resblock_type": "别墅",
    "resblock_location": [
      "房山",
      "房山其它",
      "周口店镇政府东200米"
    ],
    "resblock_room": "3室",
    "resblock_area": "建面 140-160 m²",
    "house_avg_price": "23000",
    "house_total_price": "总价320-530(万/套)"
  },
  ...
]
```

1.2 处理过程

要进行处理的关键步骤罗列如下, 详细实现在 data_process.py 中类 json2csv 中的函数 _data_process() 中:

- 去掉字符串字段中的空格, 由于去掉的是前后空格, 使用 strip() 实现.
- 面积和总价所给是一个范围, 将其求平均值并取整. 对于范围的提取和处理, 使用正则表达式配合对 None 的判断进行. 正则表达式如下.

```
# Extract the first one or two integer(s) from string.
int_re = re.compile(r"^[0-9]*(\d+)[0-9]*(\d+)?")
```

- 对缺失数据, 不进行处理.

1.2.1 求平均值的理由

相比于最小值和最大值, 平均值更能代表数据的一般特征. 采用面积和总价的最小值的话, 最终得到的统计结果会明显偏小与实际值, 难以合理反应数据分布的影响. 例如, 最小值相同的两份数据 A 和 B, A 中可能几乎都是接近最小值的数值, 而 B 中可能只有寥寥几个数值接近最小值. 使用最小值就难以对此进行表现.

因此, 这里采用了对面积和总价求平均的方式.

1.3 csv 数据格式

对 json 文件读取并进行上述处理后, 转换到作业所要求的字段名称, 并写入 csv 文件. 函数为 data_process.py 中类 json2csv 的函数 write_data() 中. csv 文件格式如下.

```
名称,类型,行政区,次级地理位置,末级地理位置,房型,面积,总价,均价  
尊悦日坛,商业类,朝阳,朝阳门外,日坛北路19号,1室,90,775,63000  
天恒摩墅,别墅,房山,房山其它,周口店镇政府东200米,3室,150,425,23000  
鲁能·格拉斯小镇,别墅,通州,通州其它,北京市通州区宋庄镇格拉斯小镇营销中心,3室,317,1762,62000  
...
```

其中, 第一行为 csv 表头, 后面每一行对应 json 格式中的一个楼盘信息.

2 数据可视化

使用 matplotlib 对处理后的数据进行可视化展示. 除了楼盘价格分布的散点图, 行政区楼盘的直方图之外, 还增加了楼盘数量分布的饼图, 以更好的体现各行政区域楼盘数量分布的特征, 通过与其楼盘均价和总价的综合参考, 可以发现更多的有关信息.

2.1 图表内容

具体图表内容如下:

- 楼盘价格分布的散点图 1.
- 各行政区楼盘均价的直方图 2.
- 各行政区楼盘总价的直方图 3.
- 楼盘数量分布的饼图 4.
- 各行政区楼盘均价和总价对比的直方图 5.

各图表展示如下:




Figure 1: 楼盘价格分布的散点图

3 程序的结构和运行

3.1 代码结构

3.1.1 数据处理部分

数据处理部分的代码实现在 `src/data_process.py` 中的 `json2csv` 类中. 该类主要完成如下三个任务:

数据读取 从 Scrapy 后处理得到的 json 文件中读取楼盘信息. 实现在成员函数 `load_data()` 中.

数据处理 按照作业要求处理读入的储存在 dict 中的数据, 将处理后的数据保存在成员 `processed_data` 中, 等待写入 csv 或数据可视化处理时调用.

写入 csv 将处理后数据写入 csv 中. 在成员函数 `write_data()` 实现.




Figure 2: 各行政区楼盘均价的直方图

3.1.2 数据可视化部分

数据可视化部分的代码实现在 `src/plot_drawer.py` 中的 `plot_drawer` 类中. 该类主要完成如下任务:

绘图参数初始化 在函数 `_add_zh_cn_support()` 中添加中文支持, 在 `_customize_colors()` 中自定义图表用到的颜色, 在 `_customize_plot()` 函数中设置其他绘图默认参数.

绘制楼盘价格分布散点图 在函数 `draw_price_scatter_plot()` 中绘制楼盘价格分布.

绘制平均均价直方图 在函数 `draw_avg_of_avg_price_bar_figure()` 中绘制行政区楼盘平均均价直方图.

绘制平均总价直方图 在函数 `draw_avg_of_total_price_bar_figure()` 中绘制行政区楼盘平均总价直方图.

绘制楼盘分布饼图 在函数 `draw_estate_distribution_pie_figure()` 中绘制楼盘分布饼图.

绘制均价和总价比较直方图 在函数 `draw_compare_avg_and_total_price_plot()` 中绘制比较各行政区楼盘均价和总价的直方图.




Figure 3: 各行政区楼盘总价的直方图

3.2 代码运行

为脚本添加了命令行参数处理. 使用如下命令可查看帮助:

```
# cwd: src/
$ python data_process.py --help

# output
usage: python data_process.py [-h] [-i INFILE] [-o OUTFILE]

A script to process lianjia data crawled from Linajia.

optional arguments:
  -h, --help show this help message and exit
  -i INFILE, --infile INFILE
                        Json file to procecss.
  -o OUTFILE, --outfile OUTFILE
                        Path to output processed csv.

author: 2020211323-2020211597 吴清柳
```

除在命令行参数中手动指定输入输出文件外, 还制作了运行脚本 `run.sh`, 运行如下命令即可读取楼盘新楼数据, 转换对应的 `csv`, 同时输出可视化结果.

```
bash run.sh
```




Figure 4: 楼盘数量分布的饼图




Figure 5: 各行政区楼盘均价和总价对比的直方图

4 附录

代码仓库: [Github](#)